Etablissement : ISET-Bizerte	**Département :** Technologies de l'Informatique
Matière : Gestion des données massives	**Année Universitaire :** 2022 - 2023
Niveau : DSI3	**Enseignants :** H. HMIDA

TD1 : HADOOP

Exercice 1 :

Répondre aux questions suivantes :

1. Quelles sont les avantages spécifiques d'un système distribué ?
   a. Haute Concurrence
   b. Tolérance aux pannes
   c. Large espace de stockage
   d. Haute disponibilité
2. Une entreprise de services a remarqué une baisse dans le nombre de nouveaux clients. Elle veut savoir la cause de ce constat. Quel type d'analyse doit-elle effectuer ?
   a. Analyse diagnostique
   b. Analyse descriptive
   c. Analyse prescriptive
   d. Analyse prédictive
   e. Analyse cognitive
3. Dans le pipeline du Big Data Analytics, à quels niveaux intervient l'intelligence artificielle ?
   a. Collecte de données
   b. Stockage de données
   c. Analyse de données
   d. Découverte de connaissances
   e. Visualisation de données
4. Une plateforme de vente en ligne collecte les avis des utilisateurs sur un des produits qu'elle met en vente. Les statistiques ont montré que 90% des avis ont donné 5 étoiles à ce produit. Mais une analyse approfondie a prouvé que 50% de ces avis sont émis par des utilisateurs qui n'ont pas acheté ce produit ou qui ne postent pas d'avis sérieux. Ces données (avis) sont caractérisées par :
   a. Basse valeur
   b. Haute valeur
   c. Basse véracité
   d. Haute véracité
5. Qu'est-ce que la vélocité des données Big Data ?
   a. La vitesse des équipements de stockage
   b. La vitesse des connexions entre les nœuds d'un cluster
   c. La vitesse de génération des données
   d. La vitesse de calcul des nœuds du cluster
6. Quels sont les défis liés à la haute variété des données ?
   a. La qualité médiocre des données
   b. Intégration difficile
   c. Analyse complexe
   d. Coût de stockage
7. Parmi ces éléments, qu'est-ce qui a contribué à l'émergence du Big Data ?
   a. IoT (Internet of Things)
   b. Cloud Computing
   c. Social Media
   d. Baisse du coût de stockage
8. Qu'est-ce que HDFS ?
   a. Système de fichiers
   b. Serveur de fichiers
   c. Système d'exploitation
   d. Protocole de communication
9. Quelles sont les étapes de Map/Reduce
   a. Map, Shuffle & sort, Split, Reduce
   b. Split, Map, Shuffle & sort, Reduce
   c. Split, Shuffle & sort, Map, Reduce
   d. Map, Split, Shuffle & sort, Reduce

Exercice 2 :

1. Décrire l'architecture de HDFS et le rôle de chaque composant.
2. Donner les étapes d'écriture de bloc sur HDFS.
3. Expliquer comment HDFS assure la scalabilité et la tolérance aux pannes.

Exercice 3 :

Soit un cluster Hadoop composé 9 nœuds organisés en 3 Racks (voir figure). Le facteur de réplication est de 5. La taille de bloc est 128 MO. On désire mettre sur HDFS les 2 fichiers : **employes.csv** de taille 550 MO et **projets.csv** de taille 512 MO.

1. Donner le nombre de blocs de chaque fichier.
2. Quel est l'effet de réduire la taille de bloc ?
3. Selon la stratégie de placement des copies de blocs de HDFS, donner la localisation des différents blocs du fichier **employes.csv** (sur la figure).
4. Appliquer la technique Erasure Coding et donner la nouvelle distribution des blocs du même. Calculer le gain en espace de stockage.

Exercice 4 :

En se basant sur l'exemple Wordcount, écrire les programmes Map Reduce permettant de réaliser les opérations suivantes :

1. Compter le nombre de mots de chaque longueur présente dans un fichier texte. C'est-à-dire combien de mots de taille 2 caractères, 3 caractères, …
2. Modifier le programme pour que le résultat soit trié par le nombre de mots.
3. On souhaite regrouper les longueurs de mots en 3 intervalles de longueurs ainsi : [1-5], [6-10] et [>10]. Pour compter les mots dont les tailles est respectivement entre 1 et5, puis entre 6 et 10 et enfin supérieures à 10. Donner 2 solutions : la première avec une seule étape Map Reduce et la seconde à deux étapes (dont la première est celle donnée en question 1).

Exercice 5 :

On souhaite afficher pour les utilisateurs d'un réseau social le nombre d'amis en commun avec un autre utilisateur quand il visite la page de ce dernier. Écrire un programme Map Reduce qui calcule le nombre d'amis en communs pour chaque paire d'utilisateurs sachant qu'on dispose d'un fichier contenant les identifiants des utilisateurs suivis des identifiants de leurs amis.

Le format de chaque ligne de ce fichier est :

Id_utilisateur : id_ami1, id_ami2, ….

Exemple : (réseau social contenant 5 utilisateurs)

10:20,30,40
20:10,30,40
30:10,20,40,50
40:10,20,30,50
50:30,40

L'idée consiste à :

1. Générer les couples d'amis à partir de chaque ligne (dans l'ordre croissant des clés couple 10-30 au lieu du couple 30-10 par exemple) :

La ligne « 10:20,30,40 » génère ainsi :

10-20:20,30,40 10-30:20,30,40 10-40:20,30,40

La ligne « 20:10,30,40 » :

10-20:10,30,40 20-30:10,30,40 20-40:10,30,40

La ligne « 30:10,20,40,50 » :

10-30:10,20,40,50 20-30:10,20,40,50 30-40:10,20,40,50 30-50:10,20,40,50

La ligne « 40:10,20,30,50 » :

10-40:10,20,30,50 20-40:10,20,30,50 30-40:10,20,30,50 40-50:10,20,30,50

La ligne « 50:30,40 » :

30-50:30,40 40-50:30,40

2. Regrouper les couples (même couleur) puis garder les éléments communs des 2 listes (remarquer que chaque couple apparaît exactement 2 fois).

10-20:20,30,40	10-20:10,30,40	→ 10-20:30,40
10-30:20,30,40	10-30:10,20,40,50	→ 10-30:20,40
10-40:20,30,40	10-40:10,20,30,50	→ 10-40:20,30
20-30:10,30,40	20-30:10,20,40,50	→ 20-30:10,40
20-40:10,30,40	20-40:10,20,30,50	→ 20-40:10,30
30-40:10,20,40,50	30-40:10,20,30,50	→ 30-40:10,20,50
30-50:10,20,40,50	30-50:30,40	→ 30-50:40,
40-50:10,20,30,50	40-50:30,40	→ 40-50:30

Exercice 6 :

Soit un fichier CSV contenant la liste des étudiants ayant la structure (NCE, nom, prénom, spécialité, niveau, groupe, moyenne). Exemple : 00025478, Ben Saber, Ahmed, DSI, 3, 2, 12.5

1. Écrire un programme MapReduce qui compte le nombre d'étudiant par groupe.
2. Écrire un programme MapReduce qui compte le nombre d'étudiant par spécialité.
3. Écrire un programme MapReduce qui calcule la moyenne générale niveau et spécialité.